

## דוח מכין מעבדה 056 Deep Learning

נתנאל רוטשילד 204937841

שבי סבטן 305340713

### 1.

א. זיהוי כתב יד מתמונה – סיווג. תיוגים : ספרות ואותיות. דוגמה : תרגום מכתבים מצולמים לכתב דיגיטלי.  
ב. מסנן דואר זבל - סיווג. תיוגים : זבל/לא זבל. דוגמה : מימוש תיבת spam.  
ג. זיהוי דובר מקטע אודיו – סיווג. תיוגים : כלל הדוברים הידועים למערכת. דוגמה : האזנה לשיחות טלפון וזיהוי גורמי עניין.  
ד. חיזוי שער מניה לאחר מספר ימים – רגרסיה. תיוגים : ערך ב-\$ בין 0 לאינסוף. דוגמה : חיזוי שער מניה לאחר מספר ימים.  
ה. חיזוי משך נסיעה בין שני יעדים – רגרסיה. תיוגים : ערך בדקות בין 0 לאינסוף. דוגמה : חיזוי משך נסיעה בין שני יעדים.

דוגמאות נוספות :

זיהוי פנים מצילום וידאו – סיווג. תיוגים : כל האנשים הידועים למערכת. דוגמה : זיהוי גורמים עוינים במצלמות אבטחה.  
השלמת משפטים/מילים – סיווג. תיוגים : מילים. השלמת משפטים לפי הקשר וידע מקדים בכתיבת הודעות.

### 2.

$$f(x, a) = \log(ax) \Rightarrow L(x) = ax$$

$$forward = f(x, a) = \log(ax)$$

$$backward_{in} = \frac{df}{dL} \frac{dL}{dx} = \frac{1}{ax} \cdot a = \frac{1}{x}$$

$$backward_{par} = \frac{df}{dL} \frac{dL}{da} = \frac{1}{ax} \cdot x = \frac{1}{a}$$

$$MSE(x, y) = (x - y)^2 \Rightarrow L(x, y) = x - y$$

$$forward = MSE(x, y) = (x - y)^2$$

$$backward_{in} = \frac{df}{dL} \frac{dL}{dx} = 2(x - y)$$

$$backward_y = \frac{df}{dL} \frac{dL}{da} = -2(x - y)$$

$$f(x) = \max(0, x)$$

$$forward = f(x)$$

$$backward_x = \frac{df}{dx} = \begin{cases} 1, & x > 0 \\ 0, & x < 0 \end{cases}$$

$$f(x, a, b) = (ax + b)^{\frac{1}{2}}$$

$$backward_{in} = \frac{df}{dL} \frac{dL}{dx} = \frac{a}{2\sqrt{ax+b}}$$

$$backward_{par} = \frac{df}{dL} \frac{dL}{da} = \frac{x}{2\sqrt{ax+b}}$$

$$backward_b = \frac{df}{dL} \frac{dL}{db} = \frac{b}{2\sqrt{ax+b}}$$

3. מהפונקציה המטריצית הנתונה בשאלה :

$$f(X) = A^T X = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \end{bmatrix}$$

ניתן לאמר שמתקיים :

$$f_1 = a_{11}x_1 + a_{21}x_2 + a_{31}x_3$$

$$f_2 = a_{12}x_1 + a_{22}x_2 + a_{32}x_3$$

ולכן פונקציית ה-BACKWARD של השכבה לפי הקלט X הינה:

$$\nabla_X f(X) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \frac{\partial f_1}{\partial x_3} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \frac{\partial f_2}{\partial x_3} \end{bmatrix} = \begin{pmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{pmatrix}$$

פונקציית ה-BACKWARD של השכבה לפי הפרמטרים הינה:

$$\nabla_A f = \begin{bmatrix} \nabla_{A_1} f_1 \\ \nabla_{A_2} f_2 \end{bmatrix} = \begin{pmatrix} \frac{\partial f_1}{\partial a_{11}} & \frac{\partial f_1}{\partial a_{21}} & \frac{\partial f_1}{\partial a_{31}} \\ \frac{\partial f_2}{\partial a_{12}} & \frac{\partial f_2}{\partial a_{22}} & \frac{\partial f_2}{\partial a_{32}} \end{pmatrix} = \begin{pmatrix} x_1 & x_2 & x_3 \\ x_1 & x_2 & x_4 \end{pmatrix}$$

4.הנגזרת של  $\sigma(z)$  הינה:

$$\sigma(z) = \frac{e^z}{1+e^z} \Rightarrow \frac{\partial \sigma(z)}{\partial z} = \frac{e^z(1+e^z) - e^z e^z}{(1+e^z)^2} = \frac{e^z}{(1+e^z)} - \frac{e^z}{(1+e^z)} \frac{e^z}{(1+e^z)} = \frac{e^z}{(1+e^z)} \left(1 - \frac{e^z}{(1+e^z)}\right) = \sigma(z)(1 - \sigma(z))$$

5.נתון בשאלה :

$$f(x) = x^2 \Rightarrow \frac{\partial f}{\partial x} = 2x, x_0 = -1$$

א. עבור  $\eta = 0.01$ :

• צעד 0:

$$x_0 = -1$$

• צעד 1:

$$x_1 = x_0 - 0.01 \cdot 2x_0 = -0.98$$

• צעד 2:

$$x_2 = x_1 - 0.01 \cdot 2x_1 = -0.9604$$

• צעד 3:

$$x_3 = x_2 - 0.01 \cdot 2x_2 = -0.9412$$

ב. עבור  $\eta = 2$ :

$$x_0 = -1$$

• צעד 0:

• צעד 1:

$$x_1 = x_0 - 2 \cdot 2x_0 = 3$$

• צעד 2:

$$x_2 = x_1 - 2 \cdot 2x_1 = -9$$

• צעד 3:

$$x_3 = x_2 - 2 \cdot 2x_2 = 27$$

6. השוני ברשתות בא לידי ביטוי בשכבות הלינאריות אשר קודמות לשכבת האקטיבציה. אנו נתארת את השכבות הלינאריות באמצעות הסימונים הבאים:

$$A_0, A_1, A_2, A_3$$

עבור הרשת השנייה מתקבל בכניסה לשכבת האקטיבציה  $A_3^T A_2^T A_1^T X$ .

עבור הרשת הראשונה מתקבל בכניסה לשכבת האקטיבציה אותו הקלט.

7. הקוד ל-ADALINE בעבור סיווג האירוסים הינו:

```

function [W, error] = adaline(X, Y, num_epochs, lr0)
% [W, error] = adaline(X, Y, num_epochs, lr0)
%adaline Train a linear classifier using backpropogation
%
% Input:
%   X, Y - training set (X is an data_dim x num_samples matrix,
%                       Y is an 1 x num_samples vector)
%   lr - learning rate/step size (float)
%   num_epochs - max. number of epochs (int)
%
% Output:
%   w - weight vector
%   error - percent of training examples that were misclassified
dataDim = size(X,1);
numSamples = size(X,2);
m=1;
% Augment X to include a bias term
X = [X; ones(1,numSamples)];

% Initialize weights
W = 0.1*rand(dataDim+1, 1);

for n = 1:num_epochs
    for i = 1:numSamples
        Y_label = Y(i); % label of data sample
        X_features = X(:,i); % features of current data sample
        lr = lr0 / m; %determining the learning rate
        Y_prediction = W' * X_features; %calculating our evaluation
        W = W - lr * X_features * ( Y_prediction - Y_label ); %updating W
    end
    plot_iris(X(1:2,:),Y, W)
end
Ypred= W' * X;
Ypred( Ypred < 0 ) = -1;
Ypred( Ypred > 0 ) = 1;
mismatch=Y-Ypred;
mismatch( mismatch ~= 0 ) = 1;
error = sum(mismatch)/numSamples;
end

```

.8

נגזרת לפי הכניסה	נגזרת לפי פרמטרים	מעבר קדמי	
$\frac{\partial}{\partial X}(W^T X) = W^T$	$\frac{\partial}{\partial W^T}(W^T X) = X$	$W^T X$	שכבה לינארית

$\sigma(W^T X)(1 - \sigma(W^T X))$	-	$\frac{e^{W^T X}}{1 + e^{W^T X}}$	סיגמואיד
$\frac{1 - y_i}{1 - \pi_{i1}} - \frac{y_i}{\pi_{i1}}$	-	$y_i \log(\pi_{i1}) - \sum_{i=1}^n (1 - y_i) \log(1 - \pi_{i1})$	NLL

9. פונקציית ה-SOFTMAX הינה:

$$\text{softmax}(o_i) = \frac{e^{o_i}}{\sum_{k=1}^N e^{o_k}} \quad , \quad p_i = \text{softmax}(o_i)$$

עבור  $I = J$  נקבל:

$$\frac{\partial p_i}{\partial o_i} = \frac{\partial}{\partial o_i} \left( \frac{e^{o_i}}{\sum_{k=1}^N e^{o_k}} \right) = \frac{e^{o_i} \sum_{k=1}^N e^{o_k} - e^{o_i} e^{o_i}}{\left( \sum_{k=1}^N e^{o_k} \right)^2} = \frac{e^{o_i}}{\sum_{k=1}^N e^{o_k}} - \left( \frac{e^{o_i}}{\sum_{k=1}^N e^{o_k}} \right)^2 = p_i - p_i^2 = p_i(1 - p_i)$$

עבור  $I \neq J$  נקבל:

$$\frac{\partial p_i}{\partial o_j} = \frac{\partial}{\partial o_j} \left( \frac{e^{o_i}}{\sum_{k=1}^N e^{o_k}} \right) = \frac{-e^{o_i} e^{o_j}}{\left( \sum_{k=1}^N e^{o_k} \right)^2} = -\frac{e^{o_i}}{\sum_{k=1}^N e^{o_k}} \frac{e^{o_j}}{\sum_{k=1}^N e^{o_k}} = -p_i p_j$$